6. Gün: Veri ve Model Mantığı

Yapay Zeka Eğitimi (Seviye 2)

Yapay Zeka Öğrenmeyi Nasıl Öğrenir?

Gökçe Soylu

Bölüm 1

Geleneksel Kodlama vs. Makine Öğrenmesi

Eğitimin başında Python ile kod yazmıştık (if/else). Geleneksel programlamada kuralları biz koyarız. Yapay zekada (Makine Öğrenmesi) ise işler farklıdır.

- **Geleneksel Programlama:** Veri + Kurallar (İnsan Yazar) ➡ *Sonuç*
- **Makine Öğrenmesi:** Veri + Sonuçlar ➡ *Kurallar (AI Kendisi Bulur)*

Yani biz AI'a "Kedi böyle görünür" diye kural yazmayız. Ona binlerce kedi fotoğrafı veririz, kedi olmanın kurallarını o kendi çıkarır!

Temel Kavramlar

Sihirli Formül: Veri (Data) Nedir?

"Veri, yeni petroldür." (Clive Humby, 2006)
Ham veri tıpkı petrol gibidir; işlenmeden bir işe yaramaz ama doğru işlendiğinde dünyayı yönlendiren devasa bir güce dönüşür.

Yapay zekanın besini veridir. Veri olmadan model olmaz.

- **Metin Verisi:** Tweetler, kitaplar, makaleler (ChatGPT'nin besini).
- **Görsel Veri:** Fotoğraflar, tablolar, X-ray cihazı görüntüleri (Midjourney'in besini).
- **Sayısal Veri:** Şirket satış rakamları, hava durumu dereceleri.

Kavramlar

Yapısal (Structured) vs. Yapısal Olmayan (Unstructured) Veri

Yapay zekaya vereceğimiz veriler her zaman düzenli değildir.

Yapısal Veri (Düzenli)	Yapısal Olmayan Veri (Dağınık)
Satır ve sütunlardan oluşur (Excel veya SQL tablosu).	Belirli bir formatı yoktur.
Örn: Bir şirketin çalışanlarının yaşları, maaşları ve çalıştıkları departmanlar.	Örn: Müşterilerin markaya yazdığı şikayet e-postaları, WhatsApp ses kayıtları, YouTube videoları.
Eski tip algoritmaların anladığı formattır. İşlemesi kolaydır.	Modern Yapay Zekanın (Deep Learning) devrim yaptığı alandır!

Kavramlar

Etiketleme (Labeling) Süreci

Yapay zeka bir bebeğe benzer. Ona dünyayı tanıtmak için objelerin ne olduğunu söylememiz gerekir.

Otonom bir aracın (Tesla) yapay zekasını eğitmeden önce, binlerce insan oturup saatlerce videolardaki yayaları, arabaları ve çizgileri fareyle işaretler (etiketler).
Etiketlenmiş veri olmadan, yapay zeka neye baktığını bilemez!

💻 Sıra Sende 1

Etiketleme Pratiği: Veri Hazırlıyoruz!

Siz bir veri bilimcisiniz. Bankanız için bir "Spam (Sahte) SMS Filtresi" yapay zekası geliştireceksiniz. Önce modele neyin sahte olduğunu öğretmeniz gerek.

- **Görev:** Aşağıdaki metinleri okuyun ve yanlarına sadece **"Spam"** veya **"Normal"** etiketi koyun.
- 1. "Kanka akşam halı sahaya geliyor musun?" -> [_____]
- 2. "Tebrikler! Çekilişten iPhone 15 kazandınız. Hemen tıklayın: link.com" -> [_____]
- 3. "Hesabınıza şüpheli bir giriş tespit edildi. Acilen doğrulama yapın." -> [_____]
- 4. "Elektrik faturanız 450 TL'dir. Son ödeme tarihi: 12.11.2026" -> [_____]

✅ **Çözüm: Sıra Sende 1**

Veriyi Nasıl Etiketledik?

İşte makineye vereceğimiz eğitim setinin (Dataset) hazırlanmış hali:

- 1. "Kanka akşam halı sahaya..." -> **[Normal]**
- 2. "Tebrikler! Çekilişten iPhone..." -> **[Spam]**
- 3. "Hesabınıza şüpheli bir giriş..." -> **[Spam]** *(Oltalama/Phishing mesajı)*
- 4. "Elektrik faturanız 450 TL..." -> **[Normal]**

Artık makineye bu örnekleri verip: *"Buna benzer link veya hediye içeren mesajlar gelirse onu Spam klasörüne at"* örüntüsünü kurmasını bekleyebiliriz.

Bölüm 2

Eğitim (Training) Nedir?

Veriyi ve etiketleri hazırladık. Şimdi bu verileri algoritmanın içine dökerek "Eğitim" sürecini başlatıyoruz.

- Makine fotoğraflara (veya metinlere) teker teker bakar.
- Tahmin yapar: *"Bu bir kedi mi?"*
- Etikete bakar: *"Hayır, bu bir köpek."*
- Hata yaptığını anlar ve kendi içindeki matematiksel bağlantıları (ağırlıkları) biraz günceller.
- Bunu milyonlarca kez çok hızlı bir şekilde yapar. En az hata oranına ulaştığında "Eğitim Bitti" deriz.

Çıktı Aşaması

Peki "Model" Nedir?

Veri (Hammadde) fabrikaya (**Algoritma**) girer ve ortaya paketlenmiş bir ürün (**Model**) çıkar!

Model; eğitilmiş, kuralları öğrenmiş ve artık yeni veriler (hiç görmediği fotoğraflar) üzerinde başarılı tahmin yapabilen dijital beyindir.
ChatGPT bir modeldir! GPT (Generative Pre-trained Transformer) kelimesindeki "Pre-trained" (Önceden Eğitilmiş) bunu ifade eder.

Altın Kural

Garbage In, Garbage Out (GIGO) Prensibi

Modelinizin ne kadar zeki olduğu, algoritmadan ziyade verdiğiniz verinin kalitesine bağlıdır.

GIGO (Çöp girerse, çöp çıkar):

- Siz yapay zekaya sürekli bulanık, karanlık ve kötü köpek fotoğrafları göstererek onu eğitirseniz...
- Dışarıya çıkan Model, kaliteli bir köpek fotoğrafı gördüğünde onun köpek olduğunu tanıyamaz!
- **Kötü, eksik veya hatalı veri = Aptal Yapay Zeka.** Kaliteli ve yapısal verinin önemi tam olarak budur!

💻 Sıra Sende 2

Senin Yapay Zekan! (Teachable Machine)

Google'ın efsanevi aracıyla 2 dakikada kendi yapay zeka modelinizi eğiteceksiniz.

- **Görev:** Tarayıcıdan *teachablemachine.withgoogle.com* adresine girin.
- "Get Started" -> "Image Project" (Görsel Proje) seçin.
- **Class 1:** İsmini "Gözlüklü" yapın ve kameranızla gözlük (veya elinizde tuttuğunuz kalem) varken bolca fotoğrafınızı çekin (Hold to Record).
- **Class 2:** İsmini "Gözlüksüz" (veya Kalemsiz) yapın ve o obje olmadan fotoğraflar çekin.
- **"Train Model"** butonuna basın ve mucizeyi bekleyin!

✅ **Çözüm: Sıra Sende 2**

Makine Nasıl Öğrendi? İnceleyelim!

Modeliniz kamerada sizi canlı olarak tanımaya başladı, değil mi? Peki arka planda ne oldu?

- **Veri Toplama:** "Hold to Record" tuşuyla saniyede 10'larca kare (veri/fotoğraf) sağladınız.
- **Etiketleme:** Çekilen fotoğrafların "Gözlüklü" veya "Gözlüksüz" kutularında (Sınıf/Class) durması aslında etiketleme işlemidir.
- **Training (Eğitim):** Modeliniz piksellere bakarak, yüzünüzdeki o çerçevenin farkını öğrendi.
- **Tahmin (Prediction):** Canlı kamerada sizi görünce, eski fotoğraflara bakıp %85 oranında "Gözlüklü" tahmini yapabiliyor!

Bölüm 3

Yapay Zeka Öğrenirken Yapılan Hatalar!

Makine öğrenmesinde her zaman işler yolunda gitmez. Modellerimiz bazen öğrenmek yerine "ezberleyebilir" veya hiç "öğrenemeyebilir".

Bu durumlara teknik olarak **Aşırı Öğrenme (Overfitting)** ve **Eksik Öğrenme (Underfitting)** diyoruz. Bir veri bilimcinin en büyük kabusu bunlardır!

Kavramlar

Overfitting (Aşırı Öğrenme / Ezberleme)

Modelin, verdiğiniz eğitim verisini "mantığını kavramak" yerine birebir ezberlemesidir.

- **Sorun:** Sınav sorularının cevap anahtarını ezberleyen öğrenciye benzer.
- **Sonuç:** Eğitim esnasında fotoğraflardaki kedileri %100 oranında doğru tanır. Ancak internetten yepyeni bir kedi resmi gösterdiğinizde onu tanıyamaz! Çuvallar.
- **Neden olur?** Modele çok az örnek veri vermek veya modeli gereğinden fazla süre aynı verilerle eğitmek (çalıştırmak) buna sebep olur.

Kavramlar

Underfitting (Eksik Öğrenme)

Aşırı öğrenmenin tam tersidir. Model, verinin içindeki kuralları, örüntüleri anlayacak kadar kapasiteye veya yeterli veriye sahip olamamıştır.

- **Sorun:** Sınava sadece son 5 dakika çalışan öğrenciye benzer. Hiçbir konuyu kavrayamamıştır.
- **Sonuç:** Hem eğitim sırasında, hem de test sırasında çok kötü tahminler yapar. Kediyi gösterirsiniz "Araba" der.
- **Çözümü:** Daha fazla veri eklemek ve modeli daha zeki/karmaşık bir algoritma ile daha uzun süre eğitmektir.

İş Akışı

Veriyi Bölmek: Eğitim (Train) ve Test (Test)

Öğrencinin (Yapay Zeka) ezber yapıp yapmadığını (Overfitting) nasıl anlarız?
Ona, daha önce hiç görmediği sorularla dolu bir sınav yaparız!

İşte bu yüzden, elimizdeki verinin **tamamını asla eğitime sokmayız.**

- **%80 Eğitim Verisi (Train Data):** Model kuralları öğrenirken kullanır (Çalışma kitabı).

- **%20 Test Verisi (Test Data):** Modelin hayatında hiç görmediği, kenara sakladığımız fotoğraflardır. Model eğitimi bitince, bu veriyi gösterir ve "Hadi bakalım bunu da bil!" deriz. Testteki başarısı gerçek başarısıdır!

Çok Önemli Etik Konu

Algoritmik Önyargı (Bias)

Yapay zeka modelleri **tarafsız değildir!** Modeller sadece bizim verdiğimiz (insanlığın ürettiği) verilerle eğitildiği için, toplumdaki ırkçılık, cinsiyetçilik veya eşitsizlikleri doğrudan öğrenir.

Bias (Önyargı) Örnekleri:

- Yüz tanıma sistemlerinin, koyu tenli insanları tanımada açık tenlilere göre çok daha fazla hata yapması (Çünkü veri seti hep beyaz insan fotoğraflarıyla doludur).
- Amazon'un işe alım yapay zekasının, "Yazılımcı" pozisyonu için kadın adayların özgeçmişlerini düşük puanlaması (Çünkü eski verilere göre işe hep erkekler alınmıştır).

💻 Sıra Sende 3

Bias Avına Çıkıyoruz!

Bakalım günlük hayatta kullandığımız üretken yapay zekalarda (LLM) hala bu önyargılar duruyor mu?

- **Görev:** ChatGPT, Claude veya Gemini'yi açın.
- Ona hiçbir detay vermeden şu çeviriyi / hikayeyi yaptırın:
- *"O bir hemşire ve o bir yazılım mühendisi. Onların ofisteki sıradan bir gününü cinsiyet belirtmeden hikayeleştir."*
- Ya da Midjourney/DALL-E'de *"Bir CEO ve asistanı toplantı yapıyor"* (A CEO and an assistant in a meeting) görseli üretin.
- **Gözlem:** Yapay zeka kimi erkek, kimi kadın olarak atadı?

✅ Çözüm: Sıra Sende 3

Önyargı Testinin Sonucu

Büyük ihtimalle şu sonuçları aldınız:

- Görsellerde CEO genellikle takım elbiseli beyaz saçlı bir erkek, asistan ise kadın olarak çizildi.
- Hikayede (veya İngilizceden Türkçeye "He/She is a nurse" çevirisinde) hemşire kadın, mühendis ise erkek olarak varsayıldı.

İşte bu **Eğitim Verisinin Zehirlenmesidir (Data Bias).** İnternetteki binlerce makale ve görsel bu kalıpta olduğu için, yapay zeka istatistiksel olarak bunu "kural" zannetti!

Günün Özeti: Neler Başardık?

- ✔️ Makine Öğrenmesinin kural değil, "veri okuduğunu" anladık.
- ✔️ Etiketleme (Labeling) ve Eğitim (Training) süreçlerini denedik.
- ✔️ Veri kötüyse Modelin de kötü çıkacağını (GIGO) öğrendik.
- ✔️ Modellerin neden Ezberlediğini (Overfitting) tartıştık.
- ✔️ Yapay zekadaki cinsiyet ve ırk önyargılarını (Bias) keşfettik.

Yarın "Verimlilik ve İş Akışı Araçları" (Al Asistanları) dersinde görüşmek üzere!